

Crítica ao Campo de Arbítrio do Avaliador

Como fazer uso do intervalo de predição corretamente

Luiz F. P. Droubi* Carlos Augusto Zilli† Willian Zonato‡ Norberto Hoccheim§

02/10/2020

Resumo

Neste trabalho são apresentados aspectos teóricos e práticos relacionados ao conceito de Campo de Arbítrio (CA) do Avaliador, dado a importância deste conceito na Engenharia de Avaliações. Foram elencados os critérios previstos na normativa que possibilitam ao avaliador fazer uso do Campo de Arbítrio, detalhando cada um destes critérios levantados e ponderando se a adoção do conceito de Campo de Arbítrio do avaliador é uma condição suficiente e necessária para a solução dos problemas práticos enfrentados pelo avaliador. Para melhor ilustrar, foram elaborados estudos de diversos casos com a geração de dados randômicos simulando o problema da micronumerosidade de dados de uma mesma característica, comparando os resultados obtidos com a adoção de diversas abordagens, fazendo uso tanto do Campo de Arbítrio do Avaliador quanto do intervalo de predição (IP) das previsões efetuadas com os modelos obtidos em cada abordagem. Outro aspecto importante abordado lateralmente neste trabalho é sobre a previsão de valores de venda a partir de dados de oferta, haja vista que a falta de dados de oferta e, em consequência a falta de um fator oferta obtido cientificamente, é um dos grandes motivos que levam os avaliadores a fazerem uso do Campo de Arbítrio. Ao final, a partir da pesquisa elaborada e dos resultados obtidos são feitas recomendações visando uma melhoria na NBR 14.653 numa eventual revisão desta.

1 Introdução

Recentemente, durante o **XX Cobreap**, foi apresentado o artigo intitulado “Crítica à Avaliação Intervalar na NBR14.653-02” (DROUBI et al., 2019). Neste trabalho recomendou-se que, eventualmente, em uma próxima revisão da parte 2 da NBR 14.653-02 (2011), a avaliação intervalar, tal como está normatizada no momento, não seja mantida como se encontra. Com base nos resultados obtidos naquele artigo, foram elaborados outros estudos, com ajustes diferentes, com o intuito de verificar a pertinência das conclusões obtidas na, assim como acrescentar alguns pontos no que tange ao Campo de Arbítrio do avaliador, especialmente no que tange à omissão de variável relevante. Também foram feitas considerações a respeito do fator oferta. Pretende-se com este trabalho deixar detalhes de uma proposta de como poder-se-ia modificar o atual consenso da avaliação intervalar numa futura revisão normativa.

*SPU/SC, lfpdroubi@gmail.com

†IFSC, carlos.zilli@ifsc.edu.br

‡SPU/SC, will.zonato@gmail.com

§UFSC, hochheim@gmail.com

2 Desenvolvimento e Fundamentação

Nesta seção serão abordados o conceito básico de campo de arbítrio, como definido pela ABNT (2011), refletindo sobre as situações em que ele é aplicável e quais seriam as alternativas básicas ao seu uso.

2.1 Campo de Arbítrio do Avaliador

A NBR 14.653-02 (ABNT, 2011) define que:

*“o Campo de Arbítrio pode ser utilizado quando **variáveis relevantes** para a avaliação do imóvel **não tiverem sido contempladas no modelo**, por escassez de dados de mercado, por inexistência de fatores de homogeneização aplicáveis ou porque essas variáveis não se apresentaram estatisticamente significantes em modelos de regressão, desde que a amplitude de até mais ou menos 15% seja suficiente para absorver as influências não consideradas e que os ajustes sejam justificados”.*

Um ponto levantado por DROUBI et al. (2019) é que a comparação dos valores arbitrados dentro do CA não deveriam ser comparados ao intervalo de confiança da regressão linear, pois o *intervalo de confiança é para a média*, ou seja, o intervalo de confiança é apenas para aferir a precisão do cálculo dos valores ajustados pela reta de regressão (média + variância explicada) e não serve para contemplar outros efeitos não calculados pelo modelo para a avaliação do bem-avaliando. Para isto, a comparação devida seria com o intervalo de predição, ou seja, o intervalo onde se encontram os valores reais observados do mercado e não apenas os valores médios (a soma da média e da variância explicada e não-explicada).

Este primeiro aspecto refere-se mais à questão da avaliação intervalar do que ao campo de arbítrio em si, e poderia ser contornado simplesmente com a mudança dos critérios da avaliação intervalar, adotando-se critérios mais adequados para a elaboração de intervalos.

Um outro ponto igualmente importante levanto por DROUBI et al. (2019), porém, diz respeito apenas ao CA: o intervalo fixo, de $\pm 15\%$, pode até ser razoável em algumas situações, mas pode levar a valores de baixíssima probabilidade de ocorrência prática em mercados de baixa variabilidade, ou ainda, pelo contrário, num mercado de grande variância, levar a valores que sequer chegam próximos dos valores extremos observados no mercado.

Porém, entende-se que DROUBI et al. (2019) não esclareceram completamente os motivos pelos quais um mercado pode vir a apresentar um modelo com um intervalo de predição tão grande, enquanto noutros o intervalo de predição pode ser mais estreito.

Como será visto a seguir, isto pode ser uma questão do próprio mercado, mas também pode estar relacionado às variáveis importantes não contempladas no modelo. Na próxima subseção será analisado um dos fatores que podem levar à omissão de variáveis importantes num modelo de avaliação de imóveis.

2.2 Escassez de dados de mercado - Micronumerosidade

Um dos fatores que levam à omissão de variáveis relevantes do modelo, o que embasa a utilização do CA do avaliador, é o critério da micronumerosidade.

De acordo com o Anexo A da referida norma, quando da utilização de variáveis dicotômicas ou qualitativas, um número mínimo de dados de cada característica, variando de 3 a 10, a depender do tamanho da amostra, devem ser efetivamente utilizados. Em geral, o número de dados de cada característica (n_i) deve ser igual a 10% do número total de dados ($n_i > 10\% n$) da amostra, limitado a um mínimo de 3 dados caso a amostra possua um número total de dados menor do que 30 ($n < 30$) e um limitante superior de 10 dados $n_i > 10$ caso a amostra possua um número de dados maior do que 100 ($n > 100$).

A NBR 14.653-02 não é clara, no entanto, sobre como proceder no caso de o avaliador encontrar em sua amostra um número de dados de uma característica menor do que o mínimo estabelecido. Existem diversas possibilidades, como:

- a. a remoção da variável que apresenta a micronumerosidade;
- b. a recodificação da variável (quando possível);
- c. a remoção dos dados que apresentam aquela característica em número insuficiente.

A depender do procedimento adotado, o avaliador obterá um modelo diferente e a implicância da adoção de cada procedimento será mostrada nos estudos de casos apresentados. Presume-se, no entanto, a partir de uma leitura global da norma, que a mesma sugere que a variável e os dados sejam removidos do modelo, pois com a remoção apenas da variável e a inclusão dos dados com características diferentes no modelo, a hipótese da homoscedasticidade dos resíduos, normalmente, não se verifica, como será mostrado, e a norma também veda a utilização de modelos em que as hipóteses da inferência clássica não se cumpram, de acordo com o *caput* do item A.2.

2.3 Inexistência de fatores de homogeneização

Ficou claro durante o **XX Cobreap** que grande parte dos avaliadores se utiliza do CA para resolver um dos maiores problemas da prática atual da Engenharia de Avaliações, que é a falta de dados de transações, o que implica na impossibilidade do cálculo de um fator oferta. A imensa maioria dos Avaliadores se valem de uma pesquisa de dados ofertados, chegando assim a um modelo para os preços de oferta, que infelizmente não corresponde a um modelo de preços de venda dos imóveis.

A atual normativa não permite a aplicação de um fator oferta aos dados pesquisados, a menos que este fator seja deduzido com a utilização de metodologia científica.

No entanto, um modelo econométrico proposto por HOROWITZ (1992) permite a previsão de preços de venda a partir de preços de oferta mais precisamente do que os que seriam obtidos com um modelo hedônico elaborado a partir dos próprios dados de venda.

Segundo Horowitz (1992, pp. 124–125), o modelo econométrico por ele proposto pode prever os preços de vendas a partir dos preços de oferta com um erro médio quadrático de apenas \$2.960, enquanto que com um modelo hedônico elaborado a partir dos próprios dados de venda foi obtido um erro de \$10.361, ou seja, um erro médio muito maior do que o erro médio obtido com o modelo econométrico proposto.

Está fora do escopo deste trabalho detalhar a abordagem de HOROWITZ (1992). Contudo, a existência de um método capaz de prever preços de venda de imóveis a partir apenas de dados de oferta, e com melhor precisão do que um modelo hedônico elaborado com os próprios dados de venda é um fator a menos em favor da utilização do CA do avaliador. Estudos devem ser levados a cabo e possivelmente o modelo tenha que ser adaptado para se

ajustar à realidade da prática da Engenharia de Avaliações no Brasil, porém a existência de tal abordagem não pode permanecer completamente ignorada como é hoje na Engenharia de Avaliações.

2.4 Falta de significância dos regressores

Um dos pontos polêmicos da NBR 14.653-02 consiste na adoção de graus de fundamentação de modelos de regressão linear. Entre os critérios utilizados para o enquadramento dos modelos nos diversos graus de fundamentação está o nível de significância máxima para a rejeição da hipótese nula de cada regressor. Está além do escopo deste artigo uma crítica pormenorizada a este critério, porém deve-se salientar que este tipo de análise de importância de regressores à partir dos p-valores dos testes de hipótese tem sido muito contestada entre os estatísticos (ver MATLOFF, 2017, p. 349; WASSERSTEIN; LAZAR, 2016).

2.5 Viés devido à omissão de variável

Nesta subseção serão apresentados aspectos teóricos a respeito da omissão de variáveis relevantes de um modelo de regressão, independentemente dos motivos que levem a esta omissão, seja por escassez de dados de mercado, seja por falta de significância do regressor.

Segundo Matloff (2017, p. 24), adicionando mais variáveis independentes a um modelo se está a reduzir o viés do modelo.

Em tese, qualquer coisa que influencie o valor da variável dependente e não esteja presente no modelo é absorvido pelo termo de erro (variação não-explicada pelo modelo), que se assume estar não-correlacionado com os regressores ($E[\varepsilon|X] = 0$). No entanto, se houver algum grau de correlação entre a variável omitida e as variáveis presentes, como os efeitos da variável omitida são absorvidas pelo termo de erro, a hipótese de independência dos resíduos não será mantida. Segundo Matloff (2017, p. 25), um modelo assim é chamado pelos economistas de modelo mal-especificado (*misspecified*), enquanto os estatísticos tratam este tipo viés como viés de modelagem (*model bias*).

De acordo com Matloff (2017, p. 25), no entanto, isto não quer dizer que se trata de um viés que tenha sido adicionado deliberadamente ao modelo, apenas quer dizer que existe no modelo um viés sistêmico, que é permanente e não desaparece, por mais que aumente-se o tamanho da amostra.

2.6 Sobreajuste

O sobreajuste ou *overfitting* em estatística é uma prática que consiste em elaborar um modelo qualquer de maneira tão complexa que, ao invés de captar o sinal, capta o ruído (MATLOFF, 2017, p. 24).

A prática, então, de se adicionar variáveis ao modelo para reduzir o viés da estimação, como visto na subseção anterior, tem um limite: a introdução de uma variável, ao diminuir o viés, também aumenta a variância das estimativas dos coeficientes do modelo. Em um determinado ponto, o benefício da adição de variáveis ao modelo será menor do que a maior variabilidade que ocorrerá na estimação, o que é chamado de *overfitting* (MATLOFF, 2017, p. 24).

Segundo Matloff (2017, p. 24), para qualquer estimador estatístico $\hat{\theta}$ com variância finita, pode ser mostrado que:

$$MSE(\hat{\theta}) = Var(\hat{\theta}) + B^2(\hat{\theta}) \quad (1)$$

Onde $MSE(\hat{\theta})$ é o erro médio quadrático associado ao estimador, $Var(\hat{\theta})$ é a variância do estimador e $B^2(\hat{\theta})$ é o quadrado do viés do estimador.

Segundo Matloff (2017, p. 25), a equação 1 mostra que, adicionando variáveis ao estimador de regressão linear, reduz-se o termo $B^2(\hat{\theta})$, porém ao custo do aumento da variância ($Var(\hat{\theta})$) e vice-versa, ao se remover variáveis do modelo, se está aumentando o viés do modelo, reduzindo, porém sua variância. De acordo com Matloff pode ser até benéfico remover variáveis de um modelo com o intuito de reduzir a variância do estimador, ao custo de aceitar um pouco de viés (MATLOFF, 2017, p. 25).

Um bom exemplo para o entendimento do problema pode ser encontrado em MATLOFF (2017, pp. 342–343), reproduzido abaixo:

Supondo uma amostra com alturas de meninos e meninas, estimar as alturas médias de ambas as populações, com variância conhecida igual a σ^2 . De acordo com Matloff, os estimadores naturais seriam:

$$\hat{\mu}_1 = \frac{1}{n} \sum_{i=1}^n X_i \quad (2)$$

$$\hat{\mu}_2 = \frac{1}{n} \sum_{i=1}^n Y_i \quad (3)$$

Porém, se o número de dados da amostra é pequeno, pode ser melhor simplificar o modelo e utilizar um único estimador para ambos os grupos:

$$\check{\mu}_i = \frac{1}{2}(\bar{X} + \bar{Y}), i = 1, 2 \quad (4)$$

O critério para a escolha do melhor estimador é o erro médio quadrático (MSE).

Ocorre que o erro médio quadrático para os estimadores das equações 2 e 3 é igual à variância dos estimadores, dado que ambos são estimadores não-viesados ($B(\hat{\mu}_1) = B(\hat{\mu}_2) = 0$):

$$MSE(\hat{\mu}_1) + MSE(\hat{\mu}_2) = 2Var(\hat{\mu}_i) = 2\frac{\sigma^2}{n} \quad (5)$$

Já para os estimadores $\check{\mu}_i$ a soma dos seus erros médios quadráticos pode ser vista na equação 6¹

$$MSE(\check{\mu}_1) + MSE(\check{\mu}_2) = \frac{\sigma^2}{n} + \frac{1}{2}(\mu_1 - \mu_2)^2 \quad (6)$$

¹Obtido através da soma das variâncias e viés quadrados dos estimadores, como pode ser visto em MATLOFF (2017, pp. 386–387).

Desta maneira, para saber qual o melhor estimador, deve-se comparar os valores dos erros médios quadráticos obtidos nas equações 5 e 6.

Caso:

$$2\frac{\sigma^2}{n} < (\mu_1 - \mu_2)^2 \quad (7)$$

Adotam-se os estimadores naturais. Caso contrário, mais vale a pena adotar o estimador único para ambos os grupos.

Deve-se ter em conta, observando-se a equação 7, que:

1. se a diferença entre as médias μ_1 e μ_2 é pequena, o estimador único é bem próximo da realidade;
2. se o número de dados n é pequeno, não há dados suficientes para se estimar com precisão os dois estimadores em separado;
3. se a variância da população é alta, também será preciso mais dados para a estimação em separado das duas médias.

Segundo Matloff (2017, p. 344), este exemplo é um problema trivial de regressão, onde deve-se escolher entre um modelo nulo ($p = 0$), e um modelo mais elaborado, com um regressor ($p = 1$), a saber, a variável dicotômica que indica se tratar de um dado de altura de menino ou menina.

Ainda de acordo com Matloff (2017, p. 344), isto pode ser estendido ao contexto genérico de modelos de regressão e classificação, com p regressores e n observações: se p é grande e/ou n é pequeno, pode ser desejável utilizar um modelo mais simples, omitindo alguns regressores em que o valor de β seja negligenciável.

De acordo com Tukey e outro trabalho mais recente de Portnoy (*apud* MATLOFF, 2017, p. 344), via de regra, devem existir no máximo \sqrt{n} regressores em um modelo de regressão para se evitar o sobreajuste do modelo.

3 Estudos de Casos

Neste trabalho foram elaborados dois estudos de casos.

No primeiro estudo de caso, que visa explorar os efeitos da omissão de variáveis relevantes nos modelos de regressão linear, foram feitas quatro simulações, variando o efeito da majoração dos valores de lotes em situação de esquina, em relação aos lotes em situação de meio de quadra.

Foi elaborado ainda um segundo estudo de caso visando obter reflexões acerca da utilização do CA quando, pelo contrário, não existem variáveis **relevantes** omitidas, ainda que haja variabilidade na amostra, o que também é normal que aconteça.

3.1 Estudo de Caso 1 – Viés devido à omissão de variável relevante

Neste Estudo de Caso foram elaborados quatro simulações de dados aleatórios para discussão de alguns fatos que são ilustrados com a aplicação de diferentes abordagens para o tratamento dos dados.

Para os quatro casos, os dados do Valor Unitário de cada lote (VU) foram criados através da seguinte equação de regressão (da população), conforme equação 8:

$$VU = \beta_0 + \beta_1 \cdot Area + \beta_2 \cdot Situacao + \varepsilon \quad (8)$$

Onde $\varepsilon \sim \mathcal{N}(0, \sigma^2)$. Para os diversos casos foram variados os valores dos coeficientes da população β_i utilizados para a geração de dados, de maneira a salientar o comportamento dos diversos modelos ajustados tanto na estimação dos coeficientes ($\hat{\beta}_i$), quando na elaboração de previsões sobre um lote de referência.

A vantagem de se trabalhar com dados gerados é que se conhece *a priori* o valor dos coeficientes (β_i) da população, já que estes estão pré-definidos. Obviamente que, com a inclusão de um ruído (ε), no ajuste dos modelos de regressão aos dados gerados, não são obtidos para os coeficientes ajustados ($\hat{\beta}_i$) exatamente os mesmos valores dos coeficientes populacionais (β_i) utilizados para a geração dos dados. Mas se o modelo estiver bem especificado, os valores estimados para os coeficientes devem ser próximos dos coeficientes utilizados para a geração dos dados, ou seja, $\hat{\beta}_i \approx \beta_i$.

Em todos os casos foram gerados dados (propositalmente) em número insuficiente (< 3) para o caso dos lotes em situação de esquina.

Foram estudadas, então, as consequências da utilização de três diferentes tipos de abordagens:

- O ajuste de um modelo de regressão com a inclusão de todos os dados, porém com a omissão da variável *situacao*, visando emular o caso previsto na definição de CA, de omissão de variável relevante do modelo devido à escassez de dados de mercado;
- O ajuste de um modelo de regressão com a exclusão dos dados de esquina, de maneira a se obter um modelo ajustado em cima de uma amostra homogênea, isto é, um amostra onde todos os dados possuem as mesmas características em relação à variável *situacao*.
- O ajuste de um modelo de regressão com a inclusão de todos os dados e todas as variáveis, apesar da recomendação em contrário da NBR 14.653-02.

3.1.1 Mercado 1

Para este exemplo os dados foram gerados através da equação 9.

$$VU = 5000 - 5 \cdot Area + 250 \cdot Situacao + \varepsilon \quad (9)$$

Onde $\varepsilon \sim \mathcal{N}(0, 200^2)$.

Neste exemplo, seja o caso de se avaliar um lote urbano de esquina com $480m^2$, baseado na amostra exibida na tabela 1, obtida com as simulações, onde *Situacao* é uma variável dicotômica que diferencia os imóveis em situação de meio de quadra (0) dos imóveis de esquina (1).

De acordo com a NBR 14.653-02, como estão disponíveis apenas 2 dados de mercado em situação de esquina, não seria possível a utilização da variável *Situacao*, devido à micronumerosidade. Neste tipo de situação (escassez de dados de mercado), a norma permite a utilização do CA.

Ou seja, segundo a NBR 14.653-02 leva a crer, poderia ser elaborado um modelo com todos os dados amostrais, com a inclusão apenas da variável *Area*, omitindo-se a variável *Situacao* e utilizar o CA para majorar o valor estimado do lote pelo modelo, por este estar em situação de esquina, *desde que a amplitude de até mais ou menos 15% seja suficiente para absorver as influências não consideradas e que os ajustes sejam justificados*.

	VU	Area	Situacao
1	3111	360	0
2	2959	360	0
3	3208	360	0
4	3328	360	0
[ht] 5	2693	480	1
6	2773	480	1
7	3105	360	0
8	3344	360	0
9	2596	480	0
10	2325	480	0

Tabela 1: Dados para M. 1.

Tabela 2: Comparação de modelos para o Ex. 1.

	Dependent variable:		
	VU		
	(1)	(2)	(3)
Constant	4.912,6 (4.438,5, 5.386,7) t = 13,3***	5.320,5 (4.786,3, 5.854,8) t = 12,8***	5.320,5 (4.820,5, 5.820,6) t = 13,6***
Area	-4,8 (-6,0, -3,7) t = -5,4***	-6,0 (-7,3, -4,6) t = -5,6***	-6,0 (-7,2, -4,7) t = -6,0***
Situacao1			272,0 (85,2, 458,7) t = 1,9**
Observations	10	8	10
R ²	0,8	0,8	0,9
Adjusted R ²	0,8	0,8	0,8
Residual Std. Error	166,8 (df = 8)	155,7 (df = 6)	145,8 (df = 7)
F Statistic	28,9*** (df = 1; 8)	31,6*** (df = 1; 6)	20,7*** (df = 2; 7)

Notas:

*p<0,3; **p<0,2; ***p<0,1

Na tabela 2 são mostrados os coeficientes dos três modelos ajustados, isso fica claro: no primeiro modelo (coluna 1), foram utilizados todos os dados e apenas a variável *Area*; no segundo modelo (coluna 2), foram utilizados apenas os dados em situação de meio-de-quadra; e no terceiro modelo (coluna 3) foram utilizados todos os dados e foi incluída a variável *Situacao*, apesar da micronumerosidade.

Com a primeira abordagem (o modelo da coluna (1)), onde foram misturados dados de esquina e de meio de quadra, esperava-se desvios em relação à homoscedasticidade dos resíduos.

No entanto, provavelmente devido à pequena diferença entre os valores dos lotes em situação de esquina e dos lotes em situação de meio de quadra, a hipótese da homoscedasticidade não pôde ser rejeitada via teste de Breusch-Pagan:

```
##
## studentized Breusch-Pagan test
##
## data: fit_a
## BP = 0.50188, df = 1, p-value = 0.4787
```


O que se percebe é que o primeiro modelo viesou para cima o coeficiente da variável Area. Ou seja, o efeito da Situação do lote, que não foi incluso no modelo, foi “absorvido” pela outra variável restante, ou seja, a variável Area. Isto ocorre porque a modelagem não respeitou um dos princípios da inferência clássica, que é a homogeneidade da amostra, haja vista que a amostra utilizada mistura imóveis em situação de meio de quadra e imóveis em situação de esquina, sem uma variável que modele esta diferença entre os dados amostrais.

Os outros dois modelos se aproximaram melhor dos coeficientes “reais” de regressão, ou seja, o valor dos coeficientes para a população (5000, -5,0 e 250). Isto se deve à homogeneidade da amostra, obtida ou através da exclusão dos dados não-homogêneos, ou com a inclusão de todos os dados e variáveis relevantes, em que pese estar em desacordo com o estabelecido pela NBR 14653-02. Deve-se notar, contudo, que a estimação foi melhor para os coeficientes obtidos com o terceiro modelo, haja vista o maior número de dados.

Pelo lado da estimação dos coeficientes, portanto, não se recomenda a utilização da primeira abordagem. A segunda abordagem é preferível à primeira, porém a terceira abordagem é ainda mais precisa que a segunda.

A tabela 3 apresenta o comportamento das diversas abordagens para a previsão de novos valores com a utilização dos modelos ajustados. Nesta tabela podem ser vistos os valores para a estimativa central e para os limites inferiores e superiores do IP (@80%) e do CA, assim como a amplitude do CA. O valor teórico, obtido utilizando-se os coeficientes de regressão para a população (β_i) seria de R\$2.850,00.

Percebe-se desta maneira que para o **primeiro modelo**, o valor adicional do lote em esquina já foi absorvido e já se encontra, em grande parte, na estimativa central efetuada com o mesmo. No **segundo modelo**, que é um modelo feito apenas para os dados de lotes em situação de meio de quadra, não há qualquer influência de lotes em situação de esquina, ficando a previsão de valores para lotes de esquina comprometida. E o **terceiro modelo**, apesar da micronumerosidade, foi o que melhor estimou o lote em situação de esquina.

Tabela 3: Comparação dos limites do IP e CA para os modelos do Ex. 1.

Abordagem	Estimativa central	IP_{inf}	IP_{sup}	Amplitude IP	CA_{inf}	CA_{sup}
1	2.596,82	2.336,28	2.857,36	20,07	2.207,29	2.986,34
2	2.460,84	2.186,26	2.735,42	22,32	2.091,71	2.829,96
3	2.732,80	2.480,22	2.985,37	18,48	2.322,88	3.142,71

Deve-se notar que, para este caso, o CA é suficiente para absorver as influências não consideradas, ou seja, com a adoção do limite superior do CA é possível chegar e ultrapassar o valor ‘real’ do imóvel, de R\$2.800,00.

3.1.2 Mercado 2

Neste segundo exemplo, foram seguidos exatamente os mesmos passos do exemplo anterior. Contudo, para a geração dos valores, foi utilizado um peso maior para os lotes de esquina, conforme a equação 10:

$$VU = 5000 - 5 \cdot area + 390 \cdot situacao + \varepsilon \quad (10)$$

Onde $\varepsilon \sim \mathcal{N}(0, 200^2)$

Os dados gerados encontram-se na tabela 4. Deve-se reparar que, aqui, erros à parte, foi adicionado R\$390,00 ao valor de um lote em situação de esquina em relação a um lote em situação de meio de quadra, o que significa um adicional de exatamente 15% ao valor do lote-padrão de 480 m^2 em situação de meio de quadra, que apresenta valor 'real' de R\$2.600,00. Ou seja, o valor do lote que se pretende prever, de 480 m^2 , em situação de esquina, neste mercado, terá valor 'real' de R\$2.990,00.

Novamente, então, foram ajustados três modelos, como os descritos no exemplo anterior.

Na tabela 5 são mostrados os coeficientes dos três modelos ajustados. Novamente fica claro que: no primeiro modelo (coluna 1), os coeficientes ajustados estão viesados, no segundo e no terceiro modelos eles estão estimados corretamente, porém o terceiro modelo é mais preciso (menores intervalos de confiança).

	VU	Area	Situacao
1	3111	360	0
2	2959	360	0
3	3208	360	0
4	3328	360	0
5	2833	480	1
6	2913	480	1
7	3105	360	0
8	3344	360	0
9	2596	480	0
10	2325	480	0

Tabela 4: Dados para M. 2.

Tabela 5: Comparação de modelos para o Ex. 2.

	Dependent variable:		
	VU		
	(1)	(2)	(3)
Constant	4.702,6 (4.135,7, 5.269,5) t = 10,6***	5.320,5 (4.786,3, 5.854,8) t = 12,8***	5.320,5 (4.820,5, 5.820,6) t = 13,6***
Area	-4,2 (-5,6, -2,9) t = -4,0***	-6,0 (-7,3, -4,6) t = -5,6***	-6,0 (-7,2, -4,7) t = -6,0***
Situacao1			412,0 (225,2, 598,7) t = 2,8***
Observations	10	8	10
R ²	0,7	0,8	0,8
Adjusted R ²	0,6	0,8	0,8
Residual Std. Error	199,5 (df = 8)	155,7 (df = 6)	145,8 (df = 7)
F Statistic	15,6*** (df = 1; 8)	31,6*** (df = 1; 6)	18,6*** (df = 2; 7)

Notas:

*p<0,3; **p<0,2; ***p<0,1

A verificação da homoscedasticidade para a primeira abordagem, neste caso, ainda se mantém:

```
##
## studentized Breusch-Pagan test
##
## data: fit_b
## BP = 2.4526, df = 1, p-value = 0.1173
```

O intervalo de predição @80% e os limites do CA para os três modelos na tabela 6. Deve-se notar que, em relação ao primeiro estudo de caso, a amplitude do IP para o primeiro modelo aumentou, enquanto a amplitude do IP para o terceiro modelo diminuiu. Na segunda abordagem, o que se obtém é o mesmo modelo do primeiro estudo de caso, portanto os intervalos de predição e de CA são exatamente os mesmos do caso anterior.

Tabela 6: Comparação dos limites do IP e CA para os modelos do Ex. 2.

Modelo	Estimativa central	IP_{inf}	IP_{sup}	Amplitude IP	CA_{inf}	CA_{sup}
1	2.666,82	2.355,25	2.978,38	23,37	2.266,79	3.066,84
2	2.460,84	2.186,26	2.735,42	22,32	2.091,71	2.829,96
3	2.872,80	2.620,22	3.125,37	17,58	2.441,88	3.303,71

3.1.3 Mercado 3

Neste terceiro caso, foram seguidos exatamente os mesmos passos dos casos anteriores. Contudo, para a geração dos valores, foi utilizado um peso maior para os lotes de esquina, conforme a equação 11:

$$VU = 5000 - 5 \cdot area + 780 \cdot situacao + \varepsilon \quad (11) \quad [ht]$$

Onde $\varepsilon \sim \mathcal{N}(0, 200^2)$

Os dados gerados encontram-se na tabela 7. Deve-se reparar que, aqui, erros à parte, foi adicionado R\$780,00 ao valor de um lote em situação de esquina em relação a um lote em situação de meio de quadra, o que significa um adicional de exatamente 30% ao valor do lote-padrão de 480 m^2 em situação de meio de quadra, que apresenta valor 'real' de R\$2.600,00. Ou seja, o valor do lote que se pretende prever, de 480 m^2 , em situação de esquina, neste mercado, terá valor 'real' de R\$3.380,00. Novamente, então, foram ajustados três modelos, como os descritos no exemplo anterior.

	VU	Area	Situacao
1	3111	360	0
2	2959	360	0
3	3208	360	0
4	3328	360	0
5	3223	480	1
6	3303	480	1
7	3105	360	0
8	3344	360	0
9	2596	480	0
10	2325	480	0

Tabela 7: Dados para M. 3.

Tabela 8: Comparação de modelos para o Ex. 3.

	Dependent variable:		
	VU		
	(1)	(2)	(3)
Constant	4.117,6 (3.005,8, 5.229,4) t = 4,7***	5.320,5 (4.786,3, 5.854,8) t = 12,8***	5.320,5 (4.820,5, 5.820,6) t = 13,6***
Area	-2,6 (-5,6, 0,4) t = -1,1*	-6,0 (-7,3, -4,6) t = -5,6***	-6,0 (-7,2, -4,7) t = -6,0***
Situacao1			802,0 (615,2, 988,7) t = 5,5***
Observations	10	8	10
R ²	0,2	0,8	0,9
Adjusted R ²	0,1	0,8	0,8
Residual Std. Error	314,6 (df = 8)	155,7 (df = 6)	145,8 (df = 7)
F Statistic	2,4** (df = 1; 8)	31,6*** (df = 1; 6)	20,7*** (df = 2; 7)

Notas:

*p<0,3; **p<0,2; ***p<0,1

Reportados erros robustos para modelo da coluna 1.

Na tabela 8 são mostrados os coeficientes dos três modelos ajustados. Novamente fica claro que: no primeiro modelo (coluna 1), os coeficientes ajustados estão viesados, no

segundo e no terceiro modelos eles estão estimados corretamente, porém o terceiro modelo é mais preciso (menores intervalos de confiança).

Com o aumento da diferença de valores médios para os lotes em situação de esquina em relação aos lotes em situação de meio de quadra, com o modelo da primeira abordagem a homoscedasticidade não pode ser verificada, segundo o teste de Breusch-Pagan:

```
##  
## studentized Breusch-Pagan test  
##  
## data: fit_c  
## BP = 6.6972, df = 1, p-value = 0.009657
```

O baixo p-valor encontrado indica que o teste rejeita a hipótese nula (da homoscedasticidade).

A presença de heteroscedasticidade também pode ser detectada visualmente através da análise da Figura 1: para os lotes de maior área (e menor VU), a grande discrepância entre os resíduos dos lotes em situação de esquina (resíduos positivos, pontos 5 e 6) e dos resíduos dos lotes em situação de meio de quadra (resíduos negativos de menor área) fazem com que a variância dos erros naquele ponto sejam maiores do que a variância dos lotes de maior área, causando a heteroscedasticidade.

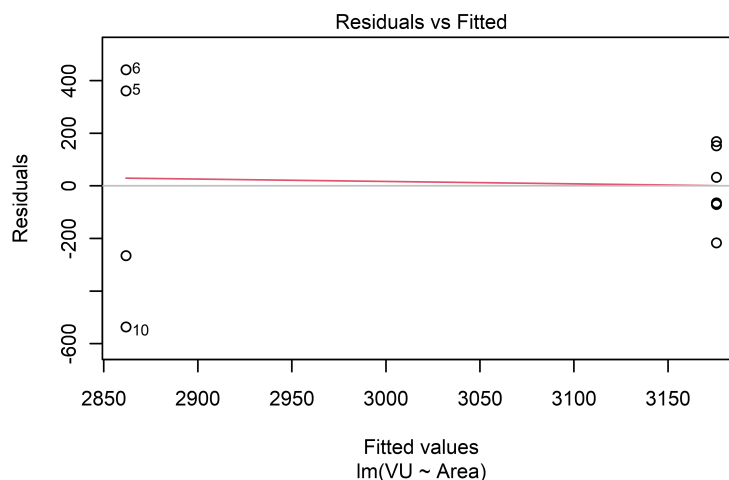


Figura 1: Gráfico de resíduos vs. valores ajustados.

Ou seja, a análise dos resíduos do modelo indica uma estrutura presente nestes resíduos. Como se sabe, esta estrutura ali presente deve-se à variável omitida: como o modelo foi ajustado considerando dados de diferentes características sem uma variável que represente esta mudança de característica, o valor do coeficiente da variável *Area* tornou-se uma espécie de média ponderada entre a redução real do do valor unitário devido ao aumento da área (para os dados de meio de quadra) e a redução menor dos valores unitários que ocorre nos dados em situação de esquina. Os erros, portanto, apesar de simétricos (há exatamente 2 dados de cada característica com $480 m^2$) serão maiores, em magnitude, para os imóveis de $480 m^2$ do que para os imóveis de $360 m^2$, donde advém a heteroscedasticidade. Na segunda abordagem, como os dados em situação de esquina foram removidos junto com a variável, este modelo resulta homoscedástico (não mostrado).

Os intervalos de confiança e predição @80% para os três modelos, bem como os limites do CA podem ser vistos na tabela 8² abaixo:

Tabela 9: Comparação dos limites do IP e CA para os modelos do Ex. 3.

Modelo	Estimativa central	IP_{inf}	IP_{sup}	Amplitude IP	CA_{inf}	CA_{sup}
1	2.861,82	2.277,70	3.445,94	40,82	2.432,54	3.291,09
2	2.460,84	2.186,26	2.735,42	22,32	2.091,71	2.829,96
3	3.262,80	3.010,22	3.515,37	15,48	2.773,38	3.752,21

Deve-se notar que, com a primeira abordagem, como o modelo é viesado, o campo de arbítrio ainda resultou suficiente para absorver os efeitos da variável omitida, o que não acontece com a segunda abordagem. Para o terceiro modelo, novamente, as previsões centrais são boas e o IP é pequeno.

3.1.4 Mercado 4

Neste quarto caso, foram seguidos exatamente os mesmos passos dos casos anteriores. Contudo, para a geração dos valores, foi adotada uma majoração maior para os lotes em situação de esquina, conforme 12. O que se buscou foi uma situação em que a amplitude do IP para a primeira abordagem extrapole a amplitude do CA.

$$VU = 5000 - 5 \cdot Area + 1500 \cdot Situacao + \varepsilon \quad (12)$$

Onde $\varepsilon \sim \mathcal{N}(0, 200^2)$

Os dados gerados encontram-se na tabela 10. Deve-se notar que os valores das estimativas centrais para os lotes em estudo, de $480 m^2$, em situação de meio de quadra ou esquina, com este modelo, serão de R\$2.600,00 e R\$4.100,00, respectivamente. O que se pretende é simular é se num mercado com uma maior variabilidade o campo de arbítrio pode ser uma bom fator limitante. Novamente, então, foram ajustados três modelos, como os descritos no exemplo anterior.

Na tabela 11 são mostrados os coeficientes dos três modelos ajustados. Novamente fica claro que: no primeiro modelo (coluna 1), os coeficientes ajustados estão viesados, no segundo e no terceiro modelos eles estão estimados corretamente, porém o terceiro modelo é mais preciso (menores intervalos de confiança).

Deve-se notar ainda na tabela 11 que o modelo da primeira abordagem, visto na coluna (1), apresentou coeficiente de ajuste baixíssimo e coeficiente de correlação ajustado negativo. O teste de significância da variável independente do modelo não foi significativo nem para enquadrar o modelo no grau I de fundamentação da NBR 14.653-02. Ainda assim este modelo faz boas previsões se utilizado corretamente o IP.

²O intervalos de predição para o modelo da primeira abordagem foram calculados com a utilização de erros robustos.

	VU	Area	Situacao
1	3111	360	0
2	2959	360	0
3	3208	360	0
4	3328	360	0
[ht] 5	3943	480	1
6	4023	480	1
7	3105	360	0
8	3344	360	0
9	2596	480	0
10	2325	480	0

Tabela 10: Dados para M. 4.

Tabela 11: Comparação de modelos para o Ex. 4.

	Dependent variable:		
	VU		
	(1)	(2)	(3)
Constant	3.037,6 (1.041,5, 5.033,6) t = 2,0***	5.320,5 (4.786,3, 5.854,8) t = 12,8***	5.320,5 (4.820,5, 5.820,6) t = 13,6***
Area	0,4 (−5,1, 5,9) t = 0,1	−6,0 (−7,3, −4,6) t = −5,6***	−6,0 (−7,2, −4,7) t = −6,0***
Situacao1			1.522,0 (1.335,2, 1.708,7) t = 10,4***
Observations	10	8	10
R ²	0,002	0,8	0,9
Adjusted R ²	−0,1	0,8	0,9
Residual Std. Error	555,1 (df = 8)	155,7 (df = 6)	145,8 (df = 7)
F Statistic	0,02 (df = 1; 8)	31,6*** (df = 1; 6)	54,6*** (df = 2; 7)

Notas:

*p<0,3; **p<0,2; ***p<0,1

Reportados erros robustos para modelo da coluna 1.

Já o modelo da segunda abordagem (coluna (2)) tem um coeficiente de ajuste muito alto e o modelo tem grau III de fundamentação, segundo a NBR 14.653-02. No entanto, este modelo é totalmente inadequado para fazer previsões fora dos dados da amostra, mesmo com a utilização do CA ou do IP.

O intervalo de predição @80% para os três modelos, bem como os limites do CA podem ser vistos na tabela 12³ abaixo:

Tabela 12: Comparação dos limites do IP e CA para os modelos do Ex. 4.

Modelo	Estimativa central	IP_{inf}	IP_{sup}	Amplitude IP	CA_{inf}	CA_{sup}
1	3.221,82	2.167,30	4.276,33	65,46	2.738,54	3.705,09
2	2.460,84	2.186,26	2.735,42	22,32	2.091,71	2.829,96
3	3.982,80	3.730,22	4.235,37	12,68	3.385,38	4.580,21

Deve-se notar que, neste mercado, como a majoração do valor unitário de um lote devido a situação esquina é grande, com a primeira abordagem o CA resultou insuficiente para absorver os efeitos da variável omitida. A segunda abordagem segue com o mesmo modelo. Já com o terceiro modelo, novamente, as previsões centrais são muito boas e o IP é pequeno.

Na primeira abordagem, deve-se notar que o IP do modelo contém o valor 'real' do lote, enquanto que o intervalo de valores dentro das semi-amplitudes de $\pm 15\%$ do CA não contém o valor 'real' do lote, já que o valor real do lote é $\approx 18,5\%$ superior à estimativa do valor central obtida com este modelo (3.221,82).

3.1.5 Resumo

Em suma, para quatro mercados diferentes (4 bairros diferentes, digamos), foram testados três tipos de abordagens diferentes:

³Os intervalos de predição e confiança para o modelo da primeira abordagem foram calculados com a utilização de erros robustos.

1. A abordagem de se considerar todos os dados, porém excluindo a variável *situacao*, por conta da micronumerosidade;
2. A abordagem de se desconsiderar, além das variáveis, também os dados em situação de esquina, chegando-se assim a um modelo apenas para os lotes em situação de meio de quadra;
3. A abordagem de utilizar-se todos os dados e todas as variáveis, apesar disso ir de encontro com a norma vigente, por conta da micronumerosidade.

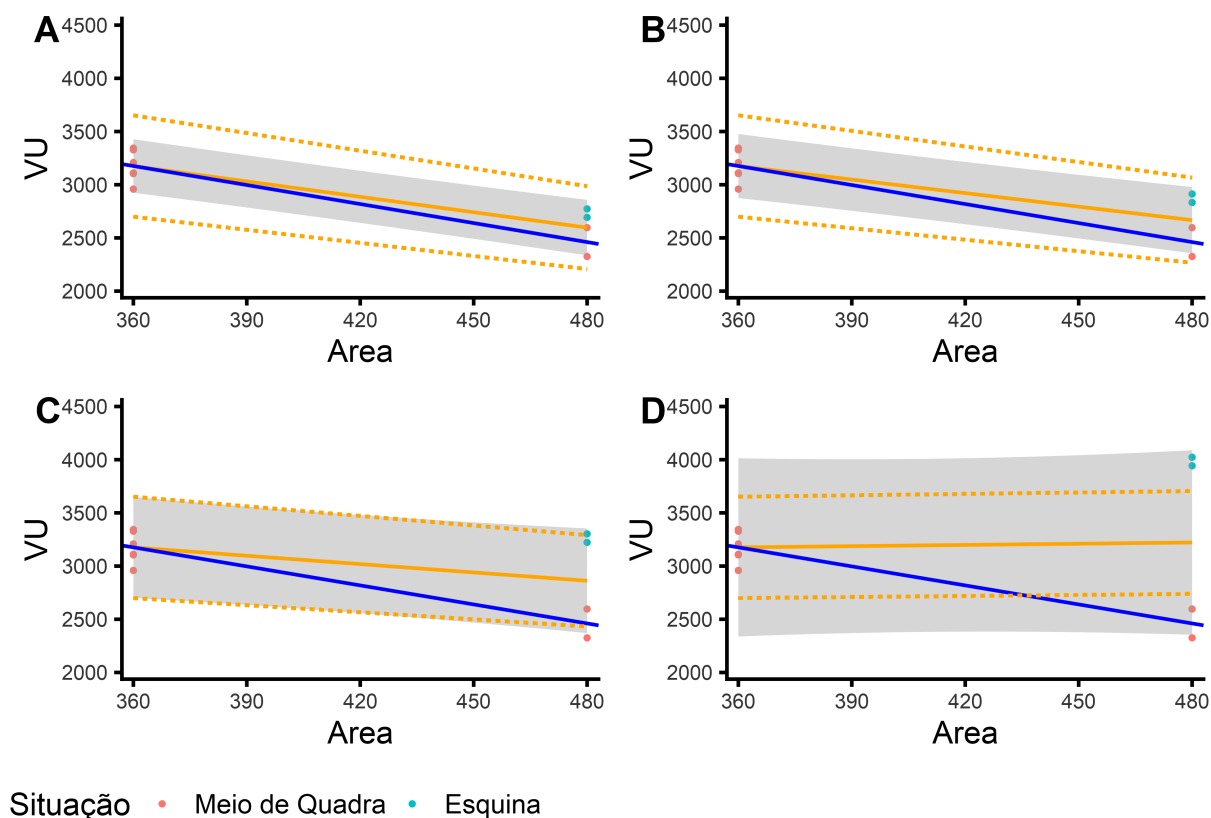


Figura 2: Gráficos dos modelos para os quatro mercados.

Os gráficos dos modelos para os quatro mercados podem ser vistos na Figura 2. Nela podem-se ver os dados do modelo acompanhados das retas de regressão para a primeira abordagem (linha cheia, em laranja) e para a segunda abordagem (em azul). Em cinza pode-se ver as bandas do IP para o modelo da primeira abordagem. As linhas laranjas tracejadas representam os limites do CA para a primeira abordagem. Deve-se notar que, como da própria definição de IP, este possui a propriedade de conter 80% dos dados previstos para o mercado, de maneira que, se a variável *Situacao* não está presente no modelo, o IP deverá se alargar de maneira a conter 80% dos dados. Num modelo bem ajustado esse intervalo é menor, já que outra variável estaria explicando a diferença de valores entre dados em situação de esquina e meio de quadra.

Em todos os mercados (bairros) a **terceira abordagem mostrou-se superior**, obtendo-se um valor de estimativa central mais próxima do valor “real”, e um IP mais estreito, além de um modelo com estimação adequada para os coeficientes.

Tabela 13: IP vs. CA em vários mercados, com diferentes abordagens.

Mercado	Abordagem	Estimativa			Valor 'real'
		Central	IP superior	CA superior	
A	1	2.596,8	2.857,4	2.986,3	2.850
	2	2.460,8	2.735,4	2.830,0	
	3	2.732,8	2.985,4	3.142,7	
B	1	2.666,8	2.978,4	3.066,8	2.990
	2	2.460,8	2.735,4	2.830,0	
	3	2.872,8	3.125,4	3.303,7	
C	1	2.861,8	3.445,9	3.291,1	3.380
	2	2.460,8	2.735,4	2.830,0	
	3	3.262,8	3.515,4	3.752,2	
D	1	3.221,8	4.276,3	3.705,1	4.100
	2	2.460,8	2.735,4	2.830,0	
	3	3.982,8	4.235,4	4.580,2	

Com a **segunda abordagem**, obtém-se sempre o mesmo modelo, com mesmos intervalos de predição e mesmos campos de arbitrio, haja vista que o que se altera nos três mercados é apenas o efeito de majoração devido à situação de esquina, cujos dados são excluídos nesta abordagem. Apesar deste modelo obter coeficientes ajustados corretamente para as demais variáveis, ele não é bom para se efetuar previsões para dados com características diferentes dos dados efetivamente utilizados na amostra. A adoção do CA ou do IP só pode ser feita completamente no escuro, sem que exista nada que possa embasar a magnitude da majoração dos valores das estimativas centrais, que são válidas apenas para os tipos de dados permanentes na amostra, no caso, os dados em situação de meio de quadra.

Tabela 14: Erros (%) obtidos com a utilização da segunda abordagem.

Mercado	Erro \hat{Y}	Erro \hat{Y}_{sup}	Erro CA_{sup}
A	-14%	-4%	-1%
B	-18%	-9%	-5%
C	-27%	-19%	-16%
D	-40%	-33%	-31%

Finalmente, com a **primeira abordagem**, apesar dos coeficientes serem estimados de maneira muito pobre, viesados por conta do efeito da variável relevante omitida, o modelo obtido é razoavelmente bom para fazer previsões, desde que se faça o uso correto do intervalo de predição. Deve-se ter em mente que o modelo não prevê como estimativa de valor central nem o valor para o lote em situação de meio de quadra, nem o valor do lote em situação de esquina, mas algo entre as duas situações. Para se prever valores dos lotes de meio de quadra deve-se minorar os valores das estimativas centrais enquanto que para os lotes de esquina, deve-se majorá-las⁴.

É possível mostrar que os modelos da primeira abordagem, independente do mercado, não apresentam homoscedasticidade, considerado o teste de Breusch-Pagan, enquanto os modelos da segunda e terceira abordagem passam no teste. Contudo, com os modelos da primeira abordagem é possível fazer boas previsões, enquanto que com os modelos da segunda abordagem isto não é possível.

Com a adoção do limite superior do IP, porém, o erro cometido com a primeira abordagem é muito pequeno, independente do mercado estudado, como ilustra a tabela abaixo. Os erros que se cometeriam ao se utilizar o limite superior do CA, comum na prática da engenharia de avaliações, é muito maior do que o erro cometido com a adoção do limite superior do IP.

Tabela 15: Erros (%) obtidos com a utilização da primeira abordagem.

Mercado	Erro \hat{Y}	Erro \hat{Y}_{sup}	Erro CA_{sup}
A	-9%	0%	5%
B	-11%	0%	3%
C	-15%	2%	-3%
D	-21%	4%	-10%

3.2 Estudo de Caso 2 – Avaliação intervalar

Os estudos de casos aqui mostrados ainda podem fornecer pistas para uma adoção de um intervalo admissível de valores condizente com a teoria estatística.

Nos casos apresentados, porém, trabalhou-se com poucas variáveis, portanto a omissão de uma das variáveis já impacta fortemente o modelo e as previsões com ele obtidas. Na prática, com mais variáveis explicando o mercado, pode ser que a omissão de uma variável tenha um impacto mais leve tanto na estimação dos coeficientes do modelo, quanto nas previsões. Assim, pode-se imaginar que a omissão de uma variável do modelo possa levar a valores estimados dentro do IP, porém não nos seus extremos, como nos casos apresentados.

Imagine-se que se saiba previamente que a amostra de trabalho não seja totalmente homogênea (na prática, ela quase nunca será). Para melhor ilustrar isto, imagine-se construir um modelo sobre uma amostra de um mercado de apartamentos em uma zona central qualquer de uma cidade, onde se saiba que existem na amostra alguns imóveis com características melhores que a média (melhor posição solar, melhor ventilação, melhor vista), porém estas características não foram contempladas no modelo - afinal não se pode fazer um modelo que contenha absolutamente todas as características, pois estas seriam muitas e o número de dados da amostra é sempre limitado. Além do mais, o que se obteria com a modelagem de

⁴Essentially, all models are wrong, but some are useful (BOX; DRAPER, 1986, p. 424).

todas as características da amostra seria um modelo com sobreajuste, que não serviria para fazer previsões de valores para dados fora da amostra.

Foram simulados dados conforme a equação 13

$$VU = 5000 - 5 \cdot Area + 250 \cdot Padrao + \varepsilon \quad (13)$$

Onde $\varepsilon \sim \mathcal{N}(0, 200^2)$

É sabido que existe correlação entre as variáveis no Mercado Imobiliário. Se um imóvel tem uma vista privilegiada, por exemplo, ele deverá ter um padrão de acabamento melhor também.

Imagine-se agora que se deva prever o valor de um novo imóvel com padrão médio, com outras características não modeladas um pouco melhores que a média (uma posição solar melhor, uma vista um pouco mais aberta), de maneira que o avaliador opte por utilizar, ao invés da estimativa central, o limite superior do IP.

Os gráficos do modelo ajustado com os dados simulados podem ser vistos na Figura 3




Figura 3: Modelo ajustado para apartamentos.

Para os dados simulados, este valor seria igual a 4.973,99. Qual seria, então, um intervalo razoável de valores admissíveis?

Como limite inferior, pode-se dizer que, com certeza, o imóvel não está abaixo da média. Logo, a estimativa de valor central seria um bom indicador de um limite inferior para os valores admissíveis: 4.734,71. E quanto ao limite superior? Neste caso, seria razoável adotar o limite superior do CA. Já que a NBR não permite que se extrapole os 15% do CA, este é o limite superior do intervalo. Caso o limite superior do IP ultrapasse os 15%, este modelo não seria aceito, mas caso o limite superior do IP esteja dentro do CA, é razoável que o intervalo de valores admissíveis esteja entre o valor central e o limite superior do CA, neste caso, 5.444,91. Em sum, adotando-se os critérios acima, o resultado da avaliação seria um intervalo como o abaixo:

$$4.734,71 \leq 4.973,99 \leq 5.444,91$$

Por outro lado, se o que se pretende com o modelo seja avaliar um imóvel de **alto padrão**, também com vista e posição solar privilegiada, etc., segundo os mesmos critérios utilizados para o imóvel de padrão médio, teria-se:

$$5.052,64 \leq 5.291,69 \leq 5.810,54$$

E, finalmente, para um imóvel de baixo padrão, acima da média em relação às outras características, teria-se:

$$4.541,18 \leq 4.779,87 \leq 5.222,36$$

Em suma, acredita-se que uma boa melhoria em termos de normatização seria obtida se a NBR 14.653 estabelecesse que, para a adoção de valores fora da estimativa central seja adotada uma amplitude máxima do IP (@80%) de 30% e que a adoção de um valor diferente da estimativa central seja feita dentro do IP. Além disto, que seja reportado um intervalo de valores admissíveis que seja coerente, com valor máximo igual à semi-amplitude do CA e valor mínimo igual à estimativa de valor central (e vice-versa: se for necessário aplicar uma minoração do valor central, que se utilize que como valor mínimo o limite inferior do CA e se adote o valor central como limite superior do intervalo de valores admissíveis).

Outra opção seria adotar um intervalo admissível sempre simétrico, com semi-amplitude igual à menor distância entre o valor adotado e o valor central ou ao valor do limite superior/inferior do CA. Neste caso, obteriam-se três intervalos simétricos, ao invés dos intervalos reportados acima:

$$4.734,71 \leq 4.973,99 \leq 5.213,27$$

$$5.052,64 \leq 5.291,69 \leq 5.530,74$$

$$4.541,18 \leq 4.779,87 \leq 5.018,55$$

4 Conclusão e Recomendações

Primeiramente, deve-se concluir que a micronumerosidade é um critério que deveria ser menos rigoroso na normatização. A presença de poucos dados pode fazer com que a estimação não seja tão boa, porém a retirada de dados ou omissão de variáveis relevantes pode ser ainda pior. A princípio, a norma deveria deixar o modelo dizer se a quantidade de dados é suficiente ou não: no caso da variável apresentar significância estatística, por que removê-la?

A opção de se retirar os dados em situação de esquina e ajustar um modelo apenas para os dados de meio de quadra (segunda abordagem) não se mostrou uma boa solução: no final o que se tem é um modelo apenas para lotes em meio de quadra, sem qualquer parâmetro para se inferir o valor dos lotes de esquina. Além do mais, dados estão sendo jogados fora (20% deles), o que faz com que a estimação dos coeficientes piorar.

A opção de se utilizar a primeira abordagem, omitindo-se a variável com problema de micronumerosidade (no caso, *Situacao*) pode ser feita, mas com o devido cuidado: o(s) valor(es) do(s) coeficiente(s) estimados para a(s) variável(eis) efetivamente utilizada(s) (no caso apenas *Area*) deve(m) ser visto(s) com ressalvas, pois nele(s) estão embutidos os efeitos da variável omitida. A estimativa central calculada com este modelo encontra-se sempre um pouco abaixo ou acima da “real”. É mais ou menos como se o modelo de regressão estivesse “errado” (todos os modelos estão errados), mas ainda fosse útil (as previsões com ele obtidas são razoáveis). O modelo, porém, avalia lotes em meio de quadra e lotes de esquina com os mesmos valores. Isto significa que as estimativas estarão apenas um pouco maiores para os lotes de meio de quadra e um pouco menores para os lotes de esquina. Mas quão maiores/menores? O intervalo de predição, nos casos apresentados, mostrou ser um bom parâmetro, enquanto o Campo de Arbítrio não se mostrou adequado.

Outra questão a ser revisada pela NBR 14.653-02 é a questão dos desvios em relação às hipóteses da inferência clássica: com a omissão de variável relevante, conforme demonstrado, o esperado é que algumas hipóteses sejam violadas, mas isto não é impeditivo da utilização do modelo: a utilização de erros robustos (Eicker-White) para os intervalos de confiança e predição podem solucionar o problema a contento.

Com relação ao Campo de Arbítrio do Avaliador, a princípio entende-se que este deva ser mantido na NBR 14.653-02, até por compatibilidade com as outras partes da NBR 14.653, mas também por compatibilidade com os outros métodos não estatísticos, como os métodos de avaliação por fatores.

A sua aplicação, contudo, deveria ser revista: primeiramente, entende-se que é um erro a livre utilização de todo o intervalo do CA sem um critério que possa dar embasamento a esta utilização. A amplitude máxima do CA deveria ser mantida, porém como limitante superior/inferior para os intervalos de valores admissíveis, não como uma opção de livre escolha para o avaliador adotar qualquer valor dentro deste intervalo, como ocorre na atual normatização. Seria boa regra permitir ao avaliador que adote valores dentro do CA, porém limitados aos valores do Intervalo de Predição do modelo de regressão linear. Ou, de outra forma, que seja permitido ao avaliador adotar qualquer valor dentro do IP, desde que este esteja dentro do intervalo de mais ou menos 15% da estimativa central.

Referências

ABNT. **NBR 14653-2: Avaliação de bens – parte 2: Imóveis urbanos**. Rio de Janeiro: Associação Brasileira de Normas Técnicas, 2011.

BOX, G. E. P.; DRAPER, N. R. **Empirical model-building and response surface**. New York, NY, USA: John Wiley & Sons, Inc., 1986.

DROUBI, L. F. P.; ZILLI, C. A.; ZONATO, W.; HOCHHEIM, N. Crítica à avaliação intervalar na NBR 14.653-02. In: XX Congresso Brasileiro de Avaliações e Perícias. **Anais...**, 2019. Florianópolis: COBREAP.

HOROWITZ, J. L. The role of the list price in housing markets: Theory and an econometric model. **Journal of Applied Econometrics**, v. 7, n. 2, p. 115–129, 1992. Disponível em: <<https://onlinelibrary.wiley.com/doi/abs/10.1002/jae.3950070202>>..

MATLOFF, N. **Statistical regression and classification: From linear models to machine learning**. Boca Raton, Florida: Chapman & Hall, 2017.

WASSERSTEIN, R. L.; LAZAR, N. A. The ASA's statement on p-values: Context, process, and purpose. **The American Statistician**, v. 70, n. 2, p. 129–133, 2016. Taylor & Francis. Disponível em: <<https://doi.org/10.1080/00031305.2016.1154108>>..